Fourier Neural Operator komponensek ECG idősor-klasszifikációban

Kutatási és publikációs terv az ERC [WP1-1] munkacsomaghoz

Szekeres Béla

2026. május

Kivonat

Ez a dokumentum az ERC kutatási terv [WP1-1] munkacsomagjához kapcsolódó önálló publikáció tervét rögzíti. A munkacsomag eredeti célja a Fourier Neural Operator (FNO) valós idősoros adathalmazokra történő kiterjesztése, különösen U-Net és attention-alapú architektúrákba integrálva, ECG-jelek osztályozási vagy anomáliaértelmezési feladataiban. A közvetlen kiindulópont a `Manuscript_so_far.md` kézirat, amely az ECG5000 adathalmazon vizsgálja, hogy FNO-komponensek javítják-e a felügyelt idősor-klasszifikációt.

A tervezett cikk fő állítása nem az, hogy az FNO általában új idősoros modellezési eszköz, hanem az, hogy párosított, paraméterszám-tudatos összehasonlításban mérhető-e a spektrális operátor hozzáadott értéke erősen kiegyensúlyozatlan ECG-klasszifikációban. A legfontosabb bizonyíték nem a puszta accuracy, hanem a macro-F1, balanced accuracy és per-class recall javulása a legközelebbi nem-FNO baseline-okhoz képest. A cikk a supervised ECG classification beállítást tekinti fő kísérleti formának, az ERC-ben szereplő "ECG anomaly detection" megfogalmazást pedig diagnosztikai ritkaosztály-felismerési motivációként kezeli. Az ECG5000 emiatt elsődlegesen ötosztályos benchmark, de kiegészítő normal-vs-abnormal bináris klasszifikáció is származtatható belőle. A cél egy reprodukálható, falszifikálható közlemény előkészítése biomedical signal processing vagy health informatics fókuszú konferenciára, majd bővített folyóiratcikkre.

Tartalomjegyzék

1. Kiinduló helyzet és vezető tézis **3**

2. Empirikus háttér a kéziratból **3**
2.1. Az ECG5000 anomáliadetektálási értelmezése 3

3. Modellek és architekturális szerep **4**
3.1. 1D U-Net és U-Net-FNO 4
3.2. Attention U-Net és Attention U-Net-FNO 4
3.3. ResNet és Fourier-enhanced residual modellek 4
3.4. Spektrogram-CNN és Spektrogram-CNN-FNO 5

4. Szakirodalmi helyzet és novelty **5**

5. Kutatási kérdések és hipotézisek **5**

6. Kísérleti protokoll **6**
6.1. Adathalmaz és split 6
6.2. Előfeldolgozás 6

6.3. Modellek és hiperparaméterek 6
6.4. Ablációs terv 6
6.5. Metrikák és döntési szabály 8
6.6. Parameter-aware értékelés 8

7. Publikációs stratégia **8**
7.1. Konferencia-opciók 8
7.2. Folyóirat-opciók 9

8. Reviewer-kockázatok és válaszok **9**

9. Végrehajtási ellenőrzőlista **10**

10. Összegzés **10**

1. Kiinduló helyzet és vezető tézis

Az ERC [WP1-1] munkacsomagja a következő célt rögzíti: az FNO-k valós idősoros adathalmazokra történő kiterjesztését, U-Net és attention-alapú architektúrákba integrálását, különös tekintettel FNO-alapú idősor-klasszifikációra, például ECG-jelek anomáliadetektálására és stacking technikákra. A kézirat jelenlegi állapota ezt a célt egy konkrét, jól körülhatárolt kísérleti kérdésre szűkíti: az ECG5000 adathalmazon javít-e az FNO a hasonló kapacitású klasszikus 1D modellekhez képest.

A vezető tézis:

> Az FNO-komponensek akkor adnak publikációsan védhető hozzájárulást ECG idősor-klasszifikációban, ha a spektrális ág nem pusztán több paramétert ad a modellhez, hanem javítja a kiegyensúlyozatlan osztályok felismerését is. Ezt párosított baseline-vs-FNO összehasonlítással, modes/layers ablációval és paraméterszám-tudatos értékeléssel kell igazolni.

Ez a megfogalmazás szándékosan szűkebb, mint egy általános "FNO jobb ECG-re" állítás. Az ECG5000 erősen imbalanced adathalmaz: a többségi osztály dominál, a ritka osztályok pedig klinikailag és módszertanilag éppen azért fontosak, mert accuracy alapján könnyen elfedhetők. Emiatt a cikk fő kérdése nem az, hogy a legjobb modell hány százalékos pontosságot ér el, hanem az, hogy az FNO javítja-e a ritka diagnosztikai mintázatok felismerését.

2. Empirikus háttér a kéziratból

A `Manuscript_so_far.md` kézirat már rögzíti a cikk alapszerkezetét. A kísérletek az ECG5000 adathalmazon zajlanak, amely a UCR/UEA idősortár egy univariáns ECG benchmarkja. Az eredeti 500/4500-as UCR split helyett a kézirat a teljes adathalmaz újraosztását tervezi:

- 60% tanító halmaz;
- 20% validációs halmaz;
- 20% teszthalmaz.

Ez ECG5000 esetén 3000 tanító, 1000 validációs és 1000 tesztmintát jelent. A felosztás stratifikált, mert a kisebbségi osztály aránya nagyon alacsony, és a random split könnyen torzíthatja a ritkaosztályos értékelést. A cikknek külön hangsúlyoznia kell, hogy az eredmények nem közvetlenül az eredeti UCR train/test split irodalmi számaival vethetők össze, hanem egy új, reprodukálható, validációs modellválasztást is lehetővé tevő protokollal.

2.1. Az ECG5000 anomáliadetektálási értelmezése

Az ECG5000 önmagában nem klasszikus anomáliadetektálási feladat, mert a minták előre címkézettek, és a modell nem kizárólag normál mintákon tanulva keres ismeretlen eltéréseket. Ezért a cikk fő állítása nem lehet az, hogy címkementes vagy novelty-detection értelemben vett ECG-anomáliadetektálást old meg. A korrekt elsődleges megfogalmazás: felügyelt, ötosztályos ECG idősor-klasszifikáció kiegyensúlyozatlan osztályeloszlás mellett.

Ugyanakkor a feladat értelmezhető anomália-motivált diagnosztikai klasszifikációként. Az 1. osztály normál beatként, a 2–5. osztályok pedig rendellenes vagy nem normál beatként összevonhatók. Ez egy származtatott bináris normal-vs-abnormal klasszifikáció, amely hasznos kiegészítő eredmény lehet, különösen az ERC-ben szereplő "ECG anomaly detection" motivációhoz. Nem válthatja ki azonban az ötosztályos értékelést, mert az összevonás elfedi a ritka

osztályok közötti különbségeket, és túl optimista képet adhat a diagnosztikai hasznosságról.

Ennek megfelelően a publikációban az ötosztályos eredmények legyenek a fő táblázatokban, a bináris normal-vs-abnormal eredmények pedig külön mellékkísérletként vagy ablációként jelenjenek meg. A bináris kísérlet célja nem új feladat definiálása, hanem annak ellenőrzése, hogy az FNO-komponens a normál és nem normál ECG-minták elkülönítésében is ad-e mérhető többletet.

Elem	Tervezett beállítás
Adathalmaz	ECG5000, UCR/UEA archive
Elsődleges feladat	ötosztályos ECG idősor-klasszifikáció
Másodlagos feladat	bináris normal-vs-abnormal klasszifikáció, class 1 kontra class 2–5
Split	60/20/20 stratifikált újrafelosztás
Normalizálás	mintánkénti z-score, $\varepsilon = 10^{-8}$ stabilizálással
Fő metrikák	accuracy, macro-F1, balanced accuracy, per-class recall
Kapacitáskontroll	parameter count és 10/15/20%-os párosítási tolerancia

1. táblázat. A WP1-1 publikáció minimális kísérleti kerete a kézirat alapján.

3. Modellek és architekturális szerep

3.1. 1D U-Net és U-Net-FNO

A compact 1D U-Net a fő encoder-decoder baseline. A modell 1D konvolúciós blokkokat, downsampling/upsampling lépéseket, skip connectionöket és adaptív poolinggal záródó klasszifikációs fejet használ. A U-Net-FNO változat a bottleneck reprezentációban alkalmaz spektrális blokkot: a rejtett idősor-reprezentációt Fourier-térbe viszi, megtartja az alacsony módusokat, tanulható komplex súlyokkal transzformálja őket, majd inverz transzformációval visszatér az időtartományba.

Ennek a modellpárnak kell adnia a cikk legfontosabb ablációját. Ha a U-Net-FNO nem javít a U-Nethez képest macro-F1 és balanced accuracy szerint, akkor a további FNO-variánsok pozitív értelmezése gyenge. Ha viszont javít, akkor a cikk fő narratívája az lehet, hogy a spektrális bottleneck olyan globális periodikus vagy frekvenciatartománybeli információt ad hozzá, amelyet a lokális konvolúció csak közvetetten tanulna meg.

3.2. Attention U-Net és Attention U-Net-FNO

Az Attention U-Net erősebb baseline, mert a skip connectionökben attention gate mechanizmust használ. Ennek szerepe nem pusztán teljesítményjavítás, hanem mechanizmusvizsgálat: ha az FNO az Attention U-Net mellett is javít, akkor a spektrális globális keverés és a figyelmi szelekció komplementer. Ha nem javít, akkor az attention gate részben kiváltja az FNO által adott információt.

3.3. ResNet és Fourier-enhanced residual modellek

A ResNet/ResNet9 modellcsalád kontrollt ad arra, hogy az FNO-hatás nem kizárólag encoder-decoder architektúrában jelenik-e meg. A CF-ResNet-1D irány különösen fontos, mert a korábbi saját munka rovarszárnycsapás-hangok osztályozásában már azt mutatta, hogy a konvolúciós és Fourier-komponensek együtt hasznosak lehetnek valós biológiai idősorokon [6].

3.4. Spektrogram-CNN és Spektrogram-CNN-FNO

A spektrogram alapú ág azt vizsgálja, hogy a spektrális információt érdemes-e fix előfeldolgozással megadni, vagy tanulható operátorként a modellbe építeni. A tervezett STFT-keresés $n_{\text{fft}} \in \{32, 64\}$, hop length $\in \{4, 8, 16\}$, Hann ablak és log-kompresszió mellett zajlik. A Spektrogram-CNN-FNO kérdése az, hogy a tanulható Fourier-operátor ad-e még plusz értéket akkor, amikor az input már eleve idő-frekvencia reprezentáció.

4. Szakirodalmi helyzet és novelty

Az ECG-idősorok mélytanulása kiterjedt terület. Nagy klinikai ECG-adathalmazokon konvolúciós és recurrent modellek már kardiológus-szintű ritmusklasszifikációt is demonstráltak [1]. Az idősortanulás tágabb irodalma szerint a convolutional és random convolutional módszerek, például az InceptionTime és a ROCKET, erős, gyakran nagyon hatékony baseline-ok [3, 4].

Az FNO eredetileg nem klasszifikációs modell, hanem neurális operátor függvényterek közötti leképezések tanulására [5]. A WP1-1 cikk újdonsága ezért nem az FNO definíciója. A védhető novelty három elemből áll:

N1. FNO-komponensek párosított vizsgálata ECG idősor-klasszifikációban több modellcsaládon.

N2. A javulás paraméterszám-tudatos elválasztása a puszta kapacitásnövekedéstől.

N3. Annak tesztelése, hogy a spektrális reprezentáció ritka ECG-osztályok felismerésében is hasznos-e, nemcsak overall accuracy szerint.

A cikkben kerülni kell azt az állítást, hogy az FNO általában új a valós idősorokon. A pontosabb állítás: ECG5000-en, reprodukálható és párosított protokollban megmérjük, hogy az FNO tanulható spektrális operátora ad-e többletet nyers jelalapú és spektrogramalapú modellekhez képest.

5. Kutatási kérdések és hipotézisek

K1. Javítja-e a U-Net-FNO a compact 1D U-Net macro-F1 és balanced accuracy értékeit azonos preprocessing és modellválasztási protokoll mellett?

K2. Megmarad-e az FNO-hatás Attention U-Net mellett, vagy az attention gate redundánssá teszi a spektrális blokkot?

K3. A ResNet-alapú Fourier-variánsokban is mérhető-e javulás, vagy az FNO-hatás főként encoder-decoder architektúrákhoz kötődik?

K4. A spektrogram-CNN-FNO ad-e többletet a sima spektrogram-CNN-hez képest, vagy a fix STFT-reprezentáció már lefedi a hasznos frekvenciainformációt?

K5. A javulás fennmarad-e 10/15/20%-os paraméterszám-tolerancia mellett, vagy csak nagyobb modellkapacitásból ered?

A fő hipotézis:

> Az FNO akkor tekinthető hasznosnak ECG5000-en, ha legalább egy nyers jelalapú modellcsaládban javítja a macro-F1 és balanced accuracy értékeket, miközben a paraméterszám-tudatos párosításban sem tűnik el a javulás.

6. Kísérleti protokoll

6.1. Adathalmaz és split

Az ECG5000 teljes adathalmazát osztálycímkék szerint stratifikáltan kell újraosztani 60/20/20 arányban. A split seed legyen rögzített, például 123. A modell seedek külön változzanak, legalább $\{0, 7, 42\}$ értékeken. A publikációban világosan szerepeljen, hogy az eredeti UCR train/test split felülírásra kerül, mert validációs modellválasztás és stabil ritkaosztályos értékelés szükséges.

6.2. Előfeldolgozás

Minden nyers ECG-mintán mintánkénti z-score normalizálás történjen:

$$\hat{x} = \frac{x - \mu(x)}{\sigma(x) + 10^{-8}}.$$

Időbeli augmentáció csak másodlagos kiegészítő kísérletként szerepelhet. A fő kísérletekben ne legyen augmentáció, hogy az FNO-hatás ne keveredjen augmentation-induced robusztussággal.

6.3. Modellek és hiperparaméterek

Modellcsalád	Fő összehasonlítás	FNO-specifikus keresés
Compact 1D U-Net	U-Net kontra U-Net-FNO	modes $\in \{8, 16, 24\}$, layers $\in \{1, 2\}$
Attention U-Net	Attention U-Net kontra Attention U-Net-FNO	ugyanaz, mint U-Net-FNO esetén
Residual modellek	ResNet/ResNet9 kontra CF-ResNet/FNO-ResNet	modes $\in \{8, 16, 24\}$, layers $\in \{1, 2\}$
Spektrogram-CNN	Spektrogram-CNN kontra Spektrogram-CNN-FNO	$m_h \in \{8, 16\}$, $m_w \in \{4, 8\}$, layers $\in \{1, 2, 3\}$

2. táblázat: A WP1-1 cikk modellcsaládjai és FNO-ablációi.

A közös hiperparaméter-rács tartalmazza a base channel width $\{16, 32, 48\}$, learning rate $\{10^{-3}, 5 \cdot 10^{-4}\}$, weight decay $\{0, 10^{-4}\}$, dropout $\{0, 0.1, 0.2\}$ értékeket. A validációs kiválasztás elsődleges metrikája macro-F1 legyen, tie-break esetén balanced accuracy, majd alacsonyabb paraméterszám.

6.4. Ablációs terv

Az ablációk nem kiegészítő díszítések, hanem a WP1-1 cikk fő bizonyítékai. A reviewer számára azt kell demonstrálniuk, hogy az FNO-blokk hatása elkülöníthető a modellcsaládtól, a paraméterszám növekedésétől, a hiperparaméter-választástól és az ECG5000 bináris normal-vs-abnormal újraértelmezésétől. Ezért a konferencia-változatban is szükséges egy minimális ablációs csomag; a folyóirati változatban pedig érdemes bővíteni az FNO-elhelyezés, a loss-választás és a második adathalmaz irányába.

Abláció	Kötelező minimum	Bővített/folyóirati értelmezés
Baseline vs FNO komponens	U-Net vs U-Net-FNO, Attention U-Net vs Attention U-Net-FNO, ResNet/ResNet9 vs FNO- vagy CF-ResNet.	A fő állítás csak akkor védhető, ha legalább egy modellcsaládban párosítottan javul a macro-F1 vagy balanced accuracy.
FNO modes/layers	Modes $\in \{8, 16, 24\}$, layers $\in \{1, 2\}$ legalább a nyers jelalapú U-Net és Attention U-Net családon.	Megmutatja, hogy az eredmény nem egyetlen szerencsés FNO-konfigurációból ered. A túl sok mód túlillesztési kockázatként is értelmezhető.
Parameter-aware kontroll	10/15/20%-os paraméterszám-toleranción belüli baseline-vs-FNO párok külön táblázata.	Ha a javulás csak nagyobb kapacitás mellett marad meg, a cikk következtetése kapacitásnövelésre, nem FNO-hatásra szűkül.
Ötosztályos vs bináris feladat	Fő táblázat: ötosztályos eredmények. Melléktáblázat: normal-vs-abnormal összevonás class 1 kontra class 2–5.	Ellenőrzi, hogy az ERC anomália-motivációja mennyire támasztható alá úgy, hogy közben nem állítunk címkementes anomaly detectiont.
FNO elhelyezése	Konferencia-változatban elég a bottleneck FNO, ha minden modellpárban azonosan dokumentált.	Folyóirati bővítés: bottleneck-only, encoder, decoder és skip utáni FNO-elhelyezés összevetése legalább U-Neten.
Osztályegyensúlyozás	Minimum: azonos loss minden baseline-vs-FNO párban, és class distribution riport.	Bővítés: cross-entropy, class-weighted cross-entropy és focal loss összevetése, mert ECG5000-en a ritka osztályok miatt a loss erősen befolyásolhatja a macro-F1-et.
Második ECG-adathalmaz	Konferencia-verzióban opcionális, de a korlátok között előre meg kell nevezni.	Folyóirati változatban MIT-BIH jellegű második validáció ajánlott a legerősebb baseline-vs-FNO párokkal, nem a teljes rács újrafuttatásával.

3. táblázat: A WP1-1 cikk minimális és bővített ablációs terve.

A cikkben az ablációkat nem célszerű pusztán appendixbe tenni. A főszövegben legalább a

baseline-vs-FNO, a modes/layers és a parameter-aware eredményeknek meg kell jelenniük, mert ezek döntik el, hogy a spektrális blokk valódi módszertani hozzájárulás-e. Az FNO-elhelyezési és loss-abláció már kezelhető folyóirati bővítésként, ha a konferencia-terjedelem szűk.

6.5. Metrikák és döntési szabály

A fő metrikák:

- test accuracy;
- macro-F1;
- balanced accuracy;
- per-class recall;
- a bináris normal-vs-abnormal mellékkísérletben abnormal sensitivity/recall, normal specificity, valamint AUROC vagy AUPRC;
- trainable parameter count.

A bináris kiegészítő értékelésnél az abnormal valószínűség számolható a softmax kimenetből $P(\text{abnormal}) = 1 - P(\text{class}\,1)$ alakban, ha az ötosztályos modell predikcióit vonjuk össze. Alternatívaként külön bináris fejet is lehet tanítani, de ezt csak mellékkísérletként szabad kezelni, mert a fő publikációs állítás az ötosztályos klasszifikációhoz kötődik.

A cikk pozitív FNO-eredményként akkor védhető, ha a legjobb FNO-változat a hozzá legközelebbi nem-FNO baseline-t legalább macro-F1 vagy balanced accuracy szerint javítja, és ez a javulás legalább két seedben konzisztens. A végső változatban per-seed táblázatot és átlag $\pm$ szórást kell közölni.

6.6. Parameter-aware értékelés

A parameter-aware összehasonlítás két lépcsőben történjen. Először minden modellcsalád legjobb konfigurációját kell rangsorolni macro-F1, balanced accuracy, accuracy, majd kisebb paraméterszám alapján. Másodszor minden baseline-vs-FNO párnál csak azokat a konfigurációkat szabad közvetlenül összevetni, amelyek paraméterszáma 10%, 15% vagy 20% tolerancián belül van. Ez közvetlenül kezeli a reviewer-kritikát, hogy az FNO pusztán nagyobb modellként nyert.

7. Publikációs stratégia

7.1. Konferencia-opciók

Konferencia	Mikor reális?	Pozicionálás/kockázat
Computing in Cardiology	Akkor jó első cél, ha a cikk fő hangsúlya ECG-specifikus, és a ritka diagnosztikai osztályok felismerése áll a középpontban.	Erős domain-fit. A módszertani novelty mérsékelt is lehet, ha az ECG-értékelés korrekt és reprodukálható.
IEEE EMBC	Reális biomedical engineering konferencia, ha a cikk jel- és adatfeldolgozási hozzájárulásként van megírva.	Jó átmenet ML és biomedical signal processing között. A reviewer-kockázat, hogy egyetlen adathalmaz kevés lehet.

Konferencia	Mikor reális?	Pozicionálás/kockázat
ICASSP/IEEE signal processing workshop	Akkor célozható, ha a spektrális operátor és a jelreprezentáció módszertani részét erősítjük.	Kevésbé ECG-specifikus, ezért erősebb összehasonlítás és tisztább signal processing narratíva kell.
ML workshop idősorokra	Akkor hasznos, ha az eredmény inkább FNO-idősoros módszertani proof-of-concept.	Jó feedback-forrás, de nem feltétlenül elég erős végső publikációs cél.

4. táblázat: Konferencia-stratégia a WP1-1 publikációhoz.

7.2. Folyóirat-opciók

Folyóirat	Mikor reális?	Pozicionálás/kockázat
IEEE Journal of Biomedical and Health Informatics	Akkor reális, ha több seed, részletes ritkaosztályos elemzés és klinikai/health informatics motiváció is szerepel.	Ambiciózus cél. Egyetlen ECG5000 benchmark önmagában kevés lehet; erős reporting és interpretáció kell.
Biomedical Signal Processing and Control	Reális első folyóiratcél, ha a cikket biomedical signal processing és ECG-reprezentációs vizsgálatként pozicionáljuk.	Nagyon jó scope-illeszkedés. A novelty-t a párosított FNO-értékelés és paraméterkontroll adja.
Artificial Intelligence in Medicine	Akkor jó cél, ha a tanulságot ritka diagnosztikai osztályok AI-alapú felismeréseként fogalmazzuk meg.	Több orvosi interpretáció és világos klinikai relevancia szükséges.
Computers in Biology and Medicine	Reális backup, ha az eredmények stabilak, de a módszertani novelty nem elég magas JBHI-hez.	Széles biomedical AI közönség. Kerülni kell a puszta benchmark-jellegű cikket.

5. táblázat: Folyóiratcélok a WP1-1 cikk bővített változatához.

8. Reviewer-kockázatok és válaszok

Várható kritika	Tervezett válasz
Az ECG5000 kicsi és erősen imbalanced.	Ezért nem accuracy a fő metrika, hanem macro-F1, balanced accuracy és per-class recall. A split stratifikált, a seedek rögzítettek.
Az FNO csak több paramétert ad.	Parameter-aware párosítást kell közölni 10/15/20%-os toleranciával, valamint paraméterszám szerinti rangsort.

Várható kritika	Tervezett válasz
A supervised classification nem azonos az ERC-ben írt anomaly detectionnel.	A cikk ezt ritkaosztályos diagnosztikai klasszifikációként pozicionálja. Az anomáliaértelmezés motiváció, nem címkementes anomaly detection állítás.
Az ECG5000 anomáliadetektálásként túl erős állítás lenne.	A cikk nem unsupervised anomaly detectionként pozicionálja az ECG5000-et, hanem főként ötosztályos supervised klasszifikációként, bináris normal-vs-abnormal mellékkísérlettel.
A spektrogram már tartalmaz frekvenciainformációt.	Ezért szerepel külön Spektrogram-CNN kontra Spektrogram-CNN-FNO összehasonlítás. Ha itt nincs javulás, az is fontos negatív kontroll.
Egyetlen adathalmaz kevés folyóirathoz.	Konferencia-változatban elfogadható lehet; folyóiratbővítéshez PhysioNet/MIT-BIH jellegű második ECG-adathalmaz hozzáadása javasolt.

6. táblázat: Reviewer-kockázatok és előre tervezett válaszok.

9. Végrehajtási ellenőrzőlista

1. Rögzíteni az ECG5000 letöltési, feldolgozási és split-generálási parancsait.
2. Exportálni minden splithez az indexlistákat, hogy a 60/20/20 felosztás reprodukálható legyen.
3. Lefuttatni a baseline modelleket: 1D U-Net, Attention U-Net, ResNet/ResNet9, Spektrogram-CNN.
4. Lefuttatni az FNO-változatokat ugyanazon train/valid/test split mellett.
5. Modes és FNO-layer ablációt végezni legalább a nyers jelalapú U-Net és Attention U-Net családon.
6. Elkészíteni a kötelező ablációs táblázatokat: baseline-vs-FNO, modes/layers, parameter-aware kontroll, ötosztályos kontra normal-vs-abnormal értékelés.
7. Folyóirati bővítéshez priorizálni az FNO-elhelyezési és loss-ablációt, majd a legerősebb modellpárokat második ECG-adathalmazon validálni.
8. Minden futáshoz menteni: konfiguráció, seed, checkpoint, history, validációs döntési metrika, tesztmetrikák, paraméterszám.
9. Elkészíteni a parameter-aware 10/15/20%-os párosított táblázatokat.
10. Külön táblázatban közölni a per-class recall értékeket, különösen a ritka osztályokra.
11. Megírni a konferencia-változatot Computing in Cardiology vagy IEEE EMBC célra.

10. Összegzés

A WP1-1 publikáció akkor lesz erős, ha nem általános FNO-ígéretként, hanem pontos idősoros mechanizmusvizsgálatként jelenik meg. Az ECG5000 jó kiindulópont, mert a ritka osztályok miatt az accuracy önmagában félrevezető, és így valóban tesztelhető, hogy a spektrális operátor

javít-e a nehéz diagnosztikai mintákon. A közlemény kulcsa a párosított baseline-vs-FNO összehasonlítás, a modes/layers abláció, a parameter-aware értékelés és a korrekt megkülönböztetés a supervised classification és az ERC-ben említett anomaly detection motiváció között.

Hivatkozások

[1] A. Y. Hannun, P. Rajpurkar, B. Haghpanahi, G. H. Tison, C. Bourn, M. P. Turakhia és A. Y. Ng. Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. *Nature Medicine*, 25, 65–69, 2019. https://doi.org/10.1038/s41591-018-0268-3

[2] H. A. Dau és mtsai. The UCR Time Series Archive. *IEEE/CAA Journal of Automatica Sinica*, 6(6), 1293–1305, 2019. https://doi.org/10.1109/JAS.2019.1911747

[3] H. Ismail Fawaz, G. Forestier, J. Weber, L. Idoumghar és P.-A. Muller. Deep learning for time series classification: a review. *Data Mining and Knowledge Discovery*, 33, 917–963, 2019. https://doi.org/10.1007/s10618-019-00619-1

[4] A. Dempster, F. Petitjean és G. I. Webb. ROCKET: exceptionally fast and accurate time series classification using random convolutional kernels. *Data Mining and Knowledge Discovery*, 34, 1454–1495, 2020. https://doi.org/10.1007/s10618-020-00701-z

[5] Z. Li, N. Kovachki, K. Azizzadenesheli, B. Liu, K. Bhattacharya, A. Stuart és A. Anandkumar. Fourier Neural Operator for Parametric Partial Differential Equations. ICLR, 2021. https://openreview.net/forum?id=c8P9NQVtmnO

[6] B. J. Szekeres, M. N. Gyöngyössy és J. Botzheim. Applying Fourier Neural Operator to insect wingbeat sound classification: Introducing CF-ResNet-1D. *Ecological Informatics*, 86, 103055, 2025. https://doi.org/10.1016/j.ecoinf.2025.103055

[7] Z. Xiong, M. P. Nash, E. Cheng, V. V. Fedorov, M. K. Stiles és J. Zhao. ECG signal classification for the detection of cardiac arrhythmias using a convolutional recurrent neural network. *Physiological Measurement*, 39(9), 094006, 2018. https://doi.org/10.1088/1361-6579/aad9ed

[8] F. Khan, X. Yu, Z. Yuan és A. U. Rehman. ECG classification using 1-D convolutional deep residual neural network. *PLOS ONE*, 18(4), e0284791, 2023. https://doi.org/10.1371/journal.pone.0284791

[9] P. N. Malleswari, V. K. Odugu, T. J. V. S. Rao és T. V. N. L. Aswini. Deep learning-assisted arrhythmia classification using 2-D ECG spectrograms. *EURASIP Journal on Advances in Signal Processing*, 2024, 104. https://doi.org/10.1186/s13634-024-01197-1

[10] M. Kachuee, S. Fazeli és M. Sarrafzadeh. ECG Heartbeat Classification: A Deep Transferable Representation. IEEE ICHI, 2018. https://doi.org/10.1109/ICHI.2018.00092